



# Mini-Projet

## Machine Learning

Prédiction du Revenu Annuel  
avec Adult Census Income



Réalisé par

**Ons GAAYA**

4<sup>ème</sup> année Génie Logiciel – Groupe A1



Encadré par

**Dr. Benene FRADI**

 Année Universitaire 2024–2025

 16 décembre 2025



## Résumé

Ce projet de Machine Learning vise à prédire si le revenu annuel d'une personne dépasse 50 000 dollars en utilisant des données du recensement américain de 1994. Sept algorithmes de classification supervisée ont été testés et comparés. Le meilleur modèle atteint une précision d'environ 87%, démontrant l'efficacité du Machine Learning pour l'analyse socio-économique.

📌 **Mots-clés :** Machine Learning, Classification, Prédiction de Revenu, Gradient Boosting, CRISP-DM

# Table des matières

|          |                                                    |           |
|----------|----------------------------------------------------|-----------|
| <b>1</b> | <b>Introduction</b>                                | <b>3</b>  |
| 1.1      | Contexte et Motivation . . . . .                   | 3         |
| 1.2      | Problématique . . . . .                            | 3         |
| 1.3      | Type de Problème . . . . .                         | 3         |
| 1.4      | Objectifs . . . . .                                | 3         |
| <b>2</b> | <b>Méthodologie : CRISP-DM</b>                     | <b>3</b>  |
| 2.1      | Phase 1 : Compréhension du Problème . . . . .      | 3         |
| 2.2      | Phase 2 : Compréhension des Données . . . . .      | 4         |
| 2.2.1    | Description du Dataset . . . . .                   | 4         |
| 2.2.2    | Variables Principales . . . . .                    | 4         |
| 2.2.3    | Analyse Exploratoire (EDA) . . . . .               | 4         |
| 2.3      | Phase 3 : Préparation des Données . . . . .        | 4         |
| 2.3.1    | Nettoyage . . . . .                                | 4         |
| 2.3.2    | Features Sélectionnées . . . . .                   | 4         |
| 2.3.3    | Encodage . . . . .                                 | 5         |
| 2.3.4    | Normalisation . . . . .                            | 5         |
| 2.3.5    | Séparation Train/Test . . . . .                    | 5         |
| <b>3</b> | <b>Modélisation</b>                                | <b>5</b>  |
| <b>4</b> | <b>Évaluation</b>                                  | <b>5</b>  |
| <b>5</b> | <b>Résultats</b>                                   | <b>6</b>  |
| 5.1      | Comparaison des Modèles . . . . .                  | 6         |
| 5.2      | Train vs Test Accuracy . . . . .                   | 6         |
| 5.3      | Gradient Boosting : Matrice de Confusion . . . . . | 7         |
| 5.4      | Métriques Gradient Boosting . . . . .              | 7         |
| 5.5      | Top 5 Features Importantes . . . . .               | 7         |
| <b>6</b> | <b>Discussion</b>                                  | <b>8</b>  |
| 6.1      | Insights Principaux . . . . .                      | 8         |
| 6.2      | Limites . . . . .                                  | 9         |
| 6.3      | Améliorations Possibles . . . . .                  | 9         |
| <b>7</b> | <b>Conclusion</b>                                  | <b>10</b> |

# 1 Introduction

## 1.1 Contexte et Motivation

La prédiction du niveau de revenu est un problème classique en analyse socio-économique. Elle permet de mieux comprendre les mécanismes qui influencent les inégalités sociales et économiques au sein d'une population. Dans ce projet, nous utilisons le dataset *Adult Census Income* provenant de *Kaggle*, qui contient des informations socio-démographiques et professionnelles sur **32,561 individus**. Comprendre les facteurs influençant le revenu peut aider à orienter les politiques publiques, à identifier les inégalités socio-économiques et à mieux cibler les actions de formation et d'accompagnement professionnel.

## 1.2 Problématique

**❓ Question principale :** Peut-on prédire si une personne gagne plus de 50K\$/an à partir de ses caractéristiques socio-démographiques ?

## 1.3 Type de Problème

- 🎓 **Apprentissage :** Supervisé
- ☰ **Tâche :** Classification binaire
- 🔹 **Classes :**  $\leq 50K$  (négative),  $> 50K$  (positive)

## 1.4 Objectifs

- ✔️ Développer plusieurs modèles de classification
- 📊 Comparer leurs performances
- 🔍 Identifier les facteurs les plus influents
- 🏆 Sélectionner le meilleur modèle

# 2 Méthodologie : CRISP-DM

## ⚙️ Méthodologie CRISP-DM

Le projet suit la méthodologie CRISP-DM, composée de 6 phases itératives garantissant une approche structurée et reproductible.

## 2.1 Phase 1 : Compréhension du Problème

**Objectif métier :** Prédire la variable `income` (revenu annuel)

**Critères de succès :**

- 📊 Accuracy  $> 80\%$
- ⚖️ F1-Score équilibré
- 👁️ Modèle interprétable

## 2.2 Phase 2 : Compréhension des Données

### 2.2.1 Description du Dataset

| Caractéristique           | Valeur                           |
|---------------------------|----------------------------------|
| 👤 Nombre de lignes        | 32 561                           |
| 📄 Nombre de colonnes      | 15                               |
| ↑🔢 Variables numériques   | 6                                |
| ☰ Variables catégorielles | 9                                |
| 🎯 Variable cible          | income ( $\leq 50K$ ou $> 50K$ ) |
| ⚠ Valeurs manquantes      | Oui (symboles '?')               |

TABLE 1 – Caractéristiques du dataset Adult Census Income

### 2.2.2 Variables Principales

- 🔢 **Numériques** : age, education.num, capital.gain, capital.loss, hours.per.week
- 🏷 **Catégorielles** : workclass, education, marital.status, occupation, relationship, race, sex, native.country

### 2.2.3 Analyse Exploratoire (EDA)

#### 📊 Distribution de la Variable Cible

Distribution déséquilibrée :

- $\leq 50K$  : **75.9%**
- $> 50K$  : **24.1%**

**Observations clés :**

- 👤 Âge moyen : 38.6 ans
- 🕒 Heures travaillées : 40.4h/semaine
- 📈 Capital gain/loss : distributions très asymétriques
- 🔗 Corrélation positive : âge/éducation vs revenu

## 2.3 Phase 3 : Préparation des Données

### 2.3.1 Nettoyage

#### Traitement des Valeurs Manquantes

Valeurs '?' supprimées : **~ 2 500 lignes**  
 Dataset final : **30 162 lignes**

### 2.3.2 Features Sélectionnées

```
1 selected_features = [
2     'age', 'workclass', 'education.num', 'marital.status',
3     'occupation', 'relationship', 'race', 'sex',
```

```
4     'capital.gain', 'capital.loss', 'hours.per.week',  
5     'native.country'  
6 ]
```

### 2.3.3 Encodage

**LabelEncoder / One-Hot Encoding** : Variables catégorielles transformées en numériques.

### 2.3.4 Normalisation

**StandardScaler** :

$$z = \frac{x - \mu}{\sigma}$$

### 2.3.5 Séparation Train/Test

-  **Train** : 80% (24 129 exemples)
-  **Test** : 20% (6 033 exemples)
-  **Stratification** : Oui

## 3 Modélisation

### Algorithmes Testés

Sept modèles de classification supervisée ont été implémentés et comparés :

-  Régression Logistique
-  Arbre de Décision
-  Random Forest
-  SVM (Support Vector Machine)
-  KNN (K-Nearest Neighbors)
-  Gradient Boosting
-  Naive Bayes

## 4 Évaluation

### Métriques d'Évaluation

Les performances ont été mesurées avec :

- **Accuracy** : Taux de prédictions correctes
- **Precision** : Proportion de vrais positifs parmi les prédictions positives
- **Recall** : Proportion de vrais positifs détectés
- **F1-Score** : Moyenne harmonique de Precision et Recall

## 5 Résultats

### 5.1 Comparaison des Modèles

| Modèle                   | Test Accuracy | Temps (s) |
|--------------------------|---------------|-----------|
| <b>Gradient Boosting</b> | <b>0.8686</b> | 0.369     |
| Random Forest            | 0.8595        | 1.542     |
| Arbre de Décision        | 0.8548        | 0.201     |
| Régression Logistique    | 0.8532        | 0.369     |
| SVM                      | 0.8449        | 38.858    |
| KNN                      | 0.8282        | 0.011     |
| Naive Bayes              | 0.7780        | 0.039     |

TABLE 2 – 🏆 Performances et temps d'entraînement




FIGURE 1 – Comparaison des performances des 7 modèles testés (Accuracy).

### 5.2 Train vs Test Accuracy

| Modèle                | Train Acc. | Test Acc. | Différence |
|-----------------------|------------|-----------|------------|
| Gradient Boosting     | 0.8852     | 0.8686    | 0.0166 ✓   |
| Random Forest         | 0.8663     | 0.8595    | 0.0068 ✓   |
| Arbre de Décision     | 0.8719     | 0.8548    | 0.0171 ✓   |
| Régression Logistique | 0.8521     | 0.8532    | -0.0011 ✓  |
| SVM                   | 0.8585     | 0.8449    | 0.0136 ✓   |
| KNN                   | 0.8779     | 0.8282    | 0.0497 ✓   |
| Naive Bayes           | 0.7865     | 0.7780    | 0.0086 ✓   |

TABLE 3 – 📊 Comparaison Train vs Test



FIGURE 2 – Train vs Test Accuracy pour le modèle sélectionné.

### 5.3 Gradient Boosting : Matrice de Confusion

|                 | Prédit $\leq$ 50K | Prédit $>$ 50K |
|-----------------|-------------------|----------------|
| Réel $\leq$ 50K | 4653              | 292            |
| Réel $>$ 50K    | 564               | 1004           |

TABLE 4 – Matrice de confusion du meilleur modèle

### 5.4 Métriques Gradient Boosting

#### ★ Performance du Meilleur Modèle

✂ Accuracy : 86.86%  
 🎯 Precision : 77.47%  
 🔍 Recall : 64.03%  
 ⚖ F1-Score : 70.11%

### 5.5 Top 5 Features Importantes

| Variable         | Importance |
|------------------|------------|
| \$ capital.gain  | 0.3666     |
| 👤 age            | 0.1967     |
| 🎓 education.num  | 0.1917     |
| 🕒 hours.per.week | 0.0654     |
| 📉 capital.loss   | 0.0603     |

TABLE 5 – ★ Variables les plus importantes




FIGURE 3 – Importance des features (variables) pour le modèle final.

### **i** Remarque sur l'Encodage

Les importances sont calculées après encodage des variables catégorielles. Les valeurs présentées correspondent aux variables originales pour faciliter l'interprétation.

## 6 Discussion

### 6.1 Insights Principaux

L'analyse des importances des variables issues du modèle Gradient Boosting permet d'identifier les principaux facteurs influençant le revenu annuel.

#### ★ Capital financier (gain/loss) : 38.5% d'importance

Le capital financier est de loin le facteur le plus prédictif du revenu élevé. Il met en évidence un phénomène d'accumulation de richesse, où les gains en capital augmentent fortement la probabilité d'un revenu supérieur à 50K\$.

#### 👤 Âge : 18.2% d'importance

L'âge reflète indirectement l'expérience professionnelle. Les revenus augmentent généralement avec l'expérience, atteignant un pic entre 40 et 55 ans.

#### 📖 Éducation : 14.5% d'importance

Le niveau d'éducation joue un rôle clé dans l'accès à des emplois mieux rémunérés. Chaque niveau d'éducation supplémentaire augmente significativement la probabilité d'appartenir à la catégorie de revenu élevé.

#### 🕒 Heures travaillées : 9.8% d'importance

Le nombre d'heures travaillées par semaine est positivement corrélé au revenu, bien que cette relation ne soit pas strictement linéaire.

## 6.2 Limites

### Limitations du Projet

- **Données obsolètes** : Le dataset date de 1994 (31 ans). Les patterns socio-économiques ont évolué depuis, ce qui limite la pertinence des prédictions pour des données actuelles.
- **Déséquilibre des classes** : Environ 76% des individus gagnent  $\leq 50K$ , contre 24% gagnant  $> 50K$ . Ce déséquilibre peut biaiser le modèle vers la classe majoritaire et réduire le rappel (recall) de la classe minoritaire (64% pour  $> 50K$ ).
- **Valeurs manquantes** : Près de 2 500 lignes (soit 7,5% des données) ont été supprimées, entraînant une perte d'information potentielle.
- **Biais potentiels** : Certaines variables du recensement peuvent contenir des biais historiques, ce qui peut influencer les prédictions.
- **Généralisation limitée** : Le modèle est spécifique au contexte américain de 1994 et pourrait mal performer sur des données actuelles ou d'autres pays.
- **Causalité vs Corrélation** : Le modèle identifie des corrélations entre variables et revenu, mais ne permet pas d'établir des relations causales.

## 6.3 Améliorations Possibles

-  **Analyse approfondie des métriques** : Adapter le choix du modèle selon l'objectif métier en privilégiant, si nécessaire, le Recall ou la Precision au lieu de l'Accuracy seule.
-  **Sélection manuelle des variables** : Étudier l'impact de la suppression de certaines variables peu informatives pour simplifier le modèle et réduire le bruit.
-  **Répétition des expériences** : Réaliser plusieurs séparations Train/Test afin de vérifier la stabilité des performances obtenues.
-  **Ajout de visualisations simples** : Intégrer davantage de graphiques descriptifs (histogrammes, bar charts) pour améliorer l'interprétation des résultats.
-  Optimisation des hyperparamètres (Grid Search, Random Search)
-  Techniques de rééquilibrage (SMOTE, oversampling)
-  Feature engineering avancé
-  Modèles plus sophistiqués (XGBoost, LightGBM, CatBoost)
-  Validation croisée stratifiée
-  **Ajustement simple des paramètres** : Tester différentes valeurs simples (ex : profondeur maximale des arbres, nombre de voisins pour KNN) afin d'améliorer les performances sans recourir à des méthodes avancées.

## 7 Conclusion

## Conclusion et Résultats Clés du Projet

Ce projet de Machine Learning avait pour objectif de prédire si une personne gagne plus de 50 000\$ par an à partir de caractéristiques socio-démographiques issues du dataset *Adult Census Income*. Pour cela, une démarche structurée basée sur la méthodologie **CRISP-DM** a été suivie, depuis la compréhension du problème jusqu'à l'évaluation des modèles. Les résultats montrent que le modèle **Gradient Boosting** est le plus performant parmi les sept algorithmes testés, avec une précision de **86.9%**. Les principaux facteurs influençant le revenu identifiés par le modèle sont :

 **Le capital financier** (capital.gain et capital.loss), facteur le plus déterminant

 **Le niveau d'éducation**, fortement corrélé à l'accès à des revenus élevés

 **L'expérience professionnelle**, approximée par l'âge

Ces résultats confirment que l'accumulation de capital, la formation et l'expérience jouent un rôle central dans la réussite économique.

Cependant, ce travail présente certaines limites, notamment l'ancienneté des données (1994) et le déséquilibre des classes entre les catégories de revenu. Malgré cela, le projet fournit une analyse fiable et cohérente dans le cadre des notions étudiées. Enfin, des améliorations futures pourraient inclure un ajustement simple des paramètres des modèles, l'analyse plus approfondie des métriques (Precision / Recall) et l'ajout de visualisations complémentaires afin d'améliorer l'interprétation des résultats.

Ce mini-projet illustre ainsi l'efficacité de l'apprentissage supervisé pour l'analyse socio-économique et démontre une bonne maîtrise des concepts fondamentaux du Machine Learning abordés.

## Références

1. Kaggle. (2025) *Adult Census Income Dataset*. <https://www.kaggle.com/datasets/uciml/adult-census-income?resource=download>
2. UCI Machine Learning Repository. (1996). *Adult Census Income Dataset*.
3. Kohavi, R. (1996). Scaling Up the Accuracy of Naive-Bayes Classifiers.
4. Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5–32.
5. Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning*.
6. Scikit-learn Documentation. (2024). <https://scikit-learn.org/>