



Ministère de l'Enseignement
Supérieur et de la Recherche
Scientifique

Année Universitaire
2025/2026



EPI DIGITAL SCHOOL
Ecole Internationale Supérieure
Privée Polytechnique de Sousse

RAPPORT DE PROJET DE FIN D'ANNÉE

Spécialité: Génie Logiciel

Intitulé

Analyse des Marchés Financiers par l'Intelligence
des Données

Lieu du stage

EPI

Réalisé par

Ons GAAYA

Encadré par

Dr. Boutheina
BEN ISMAIL

Remerciements

“La gratitude est la mémoire du cœur.”

— Alphonse de Lamartine

★ A Allah

Je rends grâce à **Allah** avant toute chose, pour la volonté, la patience et la lucidité qu’Il m’a accordées tout au long de ce travail. C’est grâce à Sa bienveillance que chaque obstacle est devenu une opportunité d’apprendre et de grandir.

★ A mes parents, mon frère et toute ma famille

Les mots ne suffiront jamais à exprimer ma reconnaissance envers mes **parents**, mes premiers enseignants, pour leur amour sans limites, leurs sacrifices invisibles et leur foi inébranlable en moi. À mon **frère**, merci pour ta complicité, ton humour et ta présence rassurante dans les moments de doute. À toute ma **famille**, vous êtes le socle sur lequel je construis chaque réussite — ce travail vous appartient autant qu’à moi.

★ A Dr. Boutheina BEN ISMAIL

J’exprime ma plus profonde gratitude à **Dr. Boutheina BEN ISMAIL**, mon encadrante, pour sa rigueur bienveillante, sa disponibilité et la qualité de ses orientations. Son encadrement a été une boussole précieuse tout au long de ce projet.

★ A l’ensemble du corps enseignant de l’EPI Sousse

Mes sincères remerciements à tous les **professeurs et formateurs de l’EPI Sousse — Digital School** pour la richesse de leur enseignement, leur passion transmise et les compétences qu’ils nous ont permis de développer tout au long de notre parcours.

★ A moi-même — Ons GAAYA

Enfin, je me permets de me féliciter, **Ons**, pour la persévérance, le courage et la détermination dont tu as fait preuve. Tu as surmonté chaque difficulté avec sérénité. Ce projet est le reflet de ton travail et de ta passion. Sois fière.

★

EPI Sousse — 2025/2026 — Ons GAAYA — GL4 A1

Résumé

Ce projet porte sur l'analyse exploratoire des marchés financiers à partir d'un dataset de **140 429 observations** couvrant **15 tickers boursiers majeurs** sur une période de **62 ans (1962–2024)**. Après un nettoyage rigoureux des données, des indicateurs techniques professionnels ont été construits (moyennes mobiles, RSI, MACD, Bandes de Bollinger, volatilité annualisée). Une analyse de corrélation a révélé trois clusters sectoriels distincts. Trois modèles de régression ont été comparés (**Régression Linéaire, Random Forest, Gradient Boosting**) pour prédire les prix futurs à **4 horizons** ($t+1$, $t+5$, $t+10$, $t+21$), atteignant un **R^2 de 0,9997** (lendemain) et démontrant une dégradation progressive jusqu'à 0,9941 à 1 mois. En bonus, un tableau de bord interactif **Streamlit** a été déployé en ligne.

Mots-clés : EDA, Python, Pandas, Scikit-Learn, Régression Linéaire, Indicateurs Techniques, Volatilité, Streamlit, Finance.

Abstract

This project presents an exploratory data analysis of financial markets using a dataset of **140,429 observations** covering **15 major stock tickers** over a period of **62 years (1962–2024)**. After thorough data cleaning, professional technical indicators were engineered (moving averages, RSI, MACD, Bollinger Bands, annualized volatility). A correlation analysis revealed three distinct sector-based clusters. Three regression models were compared (**Linear Regression, Random Forest, Gradient Boosting**) to predict future prices across **4 horizons** ($t+1$, $t+5$, $t+10$, $t+21$), achieving **$R^2 = 0.9997$** at $t+1$ and demonstrating progressive degradation to 0.9941 at 1 month. As a bonus, an interactive **Streamlit** dashboard was deployed online.

Keywords : EDA, Python, Pandas, Scikit-Learn, Linear Regression, Technical Indicators, Volatility, Streamlit, Finance.

Table des matières

Remerciements	2
Résumé	3
Abstract	3
1 Introduction et Contexte	5
1.1 Problématique	5
1.2 Objectifs du projet	5
1.3 Dataset et tickers retenus	5
2 Exploration et Nettoyage des Données (EDA)	6
2.1 Chargement par blocs (chunk reading)	6
2.2 Statistiques descriptives	6
2.3 Statistiques par Ticker	7
2.4 Nettoyage des données	8
3 Ingénierie des Caractéristiques (Feature Engineering)	8
4 Visualisation Avancée	8
4.1 Distribution des prix de clôture — Histogrammes	9
4.2 Boxplot de la volatilité annualisée	9
4.3 Heatmap de corrélation des rendements journaliers	10
4.4 Scatter — Risque vs Rendement (Markowitz)	11
4.5 Performance cumulée depuis 2015	12
4.6 Prix + MA + Bandes de Bollinger (AAPL)	12
4.7 RSI(14) et MACD (AAPL)	13
5 Modèle de Machine Learning — Régression Linéaire	13
5.1 Configuration du modèle	13
5.2 Résultats du modèle	14
5.3 Graphiques du modèle	14
5.4 Prédiction Multi-Horizons	16
5.5 Comparaison des Modèles de Régression	17
6 Bonus — Application Streamlit	18
7 Conclusion	18

1 Introduction et Contexte

1.1 Problématique

Les marchés financiers génèrent chaque jour des millions de transactions produisant des séries temporelles denses dont l’analyse requiert des outils statistiques avancés. La **volatilité** — mesure de l’instabilité des prix — constitue l’indicateur central de tout système de gestion du risque financier.

Question Centrale de Recherche

Quelles variables (techniques, statistiques, comportementales) influencent la volatilité des marchés boursiers, et peut-on prédire les prix futurs à partir de ces indicateurs ?

1.2 Objectifs du projet

- Explorer** et nettoyer un dataset boursier réel de 140 429 observations couvrant 62 ans (1962–2024) ;
- Construire** des indicateurs financiers professionnels (MA, RSI, MACD, Bollinger, Volatilité) ;
- Visualiser** les distributions, corrélations et dynamiques sectorielles ;
- Prédire** les prix futurs via régression linéaire sur **4 horizons** : $t+1$ (lendemain), $t+5$ (1 semaine), $t+10$ (2 semaines), $t+21$ (1 mois) ;
- Déployer** un tableau de bord Streamlit interactif accessible en ligne (bonus).

1.3 Dataset et tickers retenus

Le dataset provient de Kaggle (*9000+ Tickers of Stock Market Data — Full History*) et contient les données OHLCV ajustées de plus de 9 000 entreprises. Quinze tickers représentatifs de 4 secteurs ont été retenus :

Secteur	Tickers	Entreprises
Technologie	AAPL, MSFT, GOOGL	Apple, Microsoft, Alphabet
	AMZN, TSLA, META	Amazon, Tesla, Meta
	NVDA, NFLX	NVIDIA, Netflix
Finance	JPM, BAC, GS	JPMorgan, Bank of America, Goldman Sachs
Énergie/Conso	XOM, WMT, KO, PFE	ExxonMobil, Walmart, Coca-Cola, Pfizer

2 Exploration et Nettoyage des Données (EDA)

2.1 Chargement par blocs (chunk reading)

Le fichier CSV fait 3 350 MB — trop grand pour un chargement direct en mémoire sur Google Colab. Une lecture séquentielle par blocs de 100 000 lignes a été adoptée :

Code Python — Chargement par chunks

```
1 TICKERS = ['AAPL', 'MSFT', 'GOOGL', 'AMZN', 'TSLA', 'META', 'NVDA',
2           'JPM', 'BAC', 'GS', 'XOM', 'WMT', 'KO', 'PFE', 'NFLX']
3 chunks = []
4 for chunk in pd.read_csv('all_stock_data.csv', chunksize
5                           =100000):
6     filtered = chunk[chunk['Ticker'].isin(TICKERS)]
7     if not filtered.empty:
8         chunks.append(filtered)
9 df_raw = pd.concat(chunks, ignore_index=True)
# Résultat : 140 429 lignes x 9 colonnes / 1962-01-02 ->
2024-11-04
```

Résultats du chargement :

Dimensions 140 429 lignes × 9 colonnes
Période 1962-01-02 → 2024-11-04 (62 ans)
Taille CSV 3 350 MB
Plus ancien KO (Coca-Cola) : 15 819 obs. depuis 1962
Plus récent META : 3 136 obs. (IPO 2012)

2.2 Statistiques descriptives

	Open	High	Low	Close	Volume
count	140 429	140 429	140 429	140 429	140 429
mean	39.38	39.89	38.93	39.42	8.23e+07
std	78.44	79.41	77.42	78.43	2.00e+08
min	0.00	0.00	0.00	0.00	0
25%	0.59	0.62	0.57	0.59	5.72e+06
50%	10.94	11.07	10.80	10.94	1.73e+07
75%	35.63	36.10	35.14	35.65	5.99e+07

Interprétation : L'écart-type (78 \$) très élevé par rapport à la moyenne (39 \$) traduit l'hétérogénéité des tickers sur 62 ans. La médiane (10,94 \$) bien inférieure à la moyenne confirme une **asymétrie à droite** : quelques valeurs extrêmes récentes (NVDA, NFLX, MSFT) tirent la moyenne vers le haut.

2.3 Statistiques par Ticker

Ticker	Mean	Min	Max	Std	Count
META	180.55	17.73	595.94	122.80	3 136
GS	164.16	42.49	529.86	100.28	6 419
NFLX	151.28	0.37	772.07	195.74	5 652
MSFT	56.36	0.06	467.56	95.97	9 740
TSLA	78.36	1.05	409.97	103.62	3 613
AMZN	38.77	0.07	200.00	55.34	6 914
NVDA	7.26	0.01	135.71	20.04	6 489
AAPL	23.03	0.04	236.48	48.55	11 066
JPM	36.79	1.09	225.50	45.64	11 254
BAC	13.18	0.25	49.14	12.46	13 040
GOOGL	46.89	2.50	191.18	44.79	5 088
PFE	11.72	0.10	60.79	12.75	13 220
WMT	9.20	0.00	83.27	14.86	13 160
XOM	22.70	0.09	125.37	28.94	15 818
KO	12.59	0.00	73.01	17.63	15 819

Interprétation :

- **META** (Facebook/Meta) affiche le prix moyen le plus élevé (**180,55 \$**), reflet de sa croissance rapide depuis son IPO en 2012.
- **GS** (Goldman Sachs) a le deuxième prix moyen le plus élevé (164,16 \$) — l'action n'a pas subi de splits importants.
- **KO** (Coca-Cola) a le plus grand nombre d'observations (15 819) car cotée depuis 1962.
- **META** a le moins d'observations (3 136) — introduite en bourse en 2012.
- **TSLA** et **NFLX** présentent les écarts-types les plus élevés (≈ 103 et 195 \$), confirmant leur nature très volatile.
- **NVDA** affiche une valeur maximale de 135,71 \$ — prix non-ajusté après le split de juin 2024.

2.4 Nettoyage des données

Opération		Justification	Impact
Suppression Stock_Splits	Dividends,	99,9% valeurs nulles	−2 colonnes
Doublons (duplicated())		Intégrité	0 doublon
Valeurs manquantes (isnull())		Complétude	0 NaN
Filtre <code>Close > 0</code>		Donnée corrompue	−1 ligne
Dataset final			140 428 × 7

Choix technique — Conservation des outliers : En finance, une valeur extrême représente généralement un événement réel (crise 2008, krach COVID-19 2020, explosion GPU/IA 2023) porteur d’une information décisionnelle précieuse. Seule la ligne avec `Close = 0` a été retirée comme donnée corrompue.

3 Ingénierie des Caractéristiques (Feature Engineering)

Indicateur	Formule	Rôle financier
MA_20	$\frac{1}{20} \sum_{i=0}^{19} C_{t-i}$	Tendance court terme
MA_50	$\frac{1}{50} \sum_{i=0}^{49} C_{t-i}$	Tendance moyen terme
Volatility_20	$\sigma_{20} \times \sqrt{252}$	Volatilité annualisée
RSI_14	$100 - \frac{100}{1+RS}$	Surachat (> 70) / survente (< 30)
MACD	$EMA_{12} - EMA_{26}$	Momentum de tendance
BB_Upper/Lower	$MA_{20} \pm 2\sigma_{20}$	Bandes de volatilité
Target	C_{t+1}	Variable cible (prix demain)

Dataset après feature engineering : 140 428 lignes × **21 colonnes** (7 colonnes brutes + 14 indicateurs calculés)

4 Visualisation Avancée

4.1 Distribution des prix de clôture — Histogrammes




FIGURE 1 – Distribution des prix de clôture pour les 15 tickers (1962–2024). Ligne rouge = moyenne, ligne verte = médiane.

Interprétation : NVDA et TSLA présentent les distributions les plus asymétriques (*skewness* élevé) : leurs prix ont explosé récemment (boom de l'IA pour NVDA en 2023, véhicules électriques pour TSLA en 2020–2021). KO et WMT montrent des distributions compactes, typiques d'actions **défensives matures**. La moyenne est systématiquement supérieure à la médiane : **asymétrie positive** pour tous les tickers.

4.2 Boxplot de la volatilité annualisée




FIGURE 2 – Boxplot de la volatilité annualisée par ticker, trié par médiane décroissante.

Interprétation : TSLA domine avec la volatilité la plus élevée (médiane $\approx 60\text{--}80\%$), confirmant son statut spéculatif. À l’opposé, KO et WMT affichent les volatilités les plus faibles ($\approx 15\text{--}25\%$) : valeurs défensives stables. Les moustaches très longues correspondent aux pics lors de la **crise 2008** et du **krach COVID-19 mars 2020**.

4.3 Heatmap de corrélation des rendements journaliers




FIGURE 3 – Heatmap de corrélation des rendements journaliers entre les 15 tickers.

Paire	Corrélation	Interprétation
BAC – JPM	0.69	Très forte — deux grandes banques US
BAC – GS	0.66	Forte — secteur financier
AAPL – GOOGL	0.52	Forte — même écosystème Tech
XOM – AAPL	≈ 0.20	Très faible — énergie vs tech

Interprétation : Trois clusters sectoriels apparaissent : (1) **Big Tech** (AAPL, MSFT, GOOGL, META, NVDA) corrélations 0,5–0,7; (2) **Banques** (JPM, BAC, GS) 0,66–0,69; (3) **Défensifs** (KO, WMT, XOM) faiblement corrélés. Cette structure confirme l’intérêt de la **diversification sectorielle**.

4.4 Scatter — Risque vs Rendement (Markowitz)




FIGURE 4 – Scatter plot Risque vs Rendement annualisé par ticker.

Interprétation : Le graphique confirme la **théorie moderne du portefeuille de Markowitz (1952)** : actions à fort rendement = plus risquées. NVDA se distingue avec le meilleur rapport rendement/risque, portée par le boom de l'IA en 2023 (+240%). KO et WMT incarnent le profil défensif : faible risque, faible rendement, dividendes réguliers.

4.5 Performance cumulée depuis 2015




FIGURE 5 – Performance cumulée des 15 tickers depuis 2015 (base 100). NVDA se distingue nettement grâce au boom de l'IA en 2023.

4.6 Prix + MA + Bandes de Bollinger (AAPL)




FIGURE 6 – AAPL — Prix de clôture + MA20 + MA50 + Bandes de Bollinger (2019–2024).

4.7 RSI(14) et MACD (AAPL)




FIGURE 7 – AAPL — RSI(14) avec zones surachat/survente + MACD avec histogramme (2019–2024).

RSI : $RSI > 70$ = surachat (signal de vente probable). $RSI < 30$ = survente (signal d'achat potentiel).

MACD : Quand la ligne MACD croise la ligne Signal vers le haut, c'est un signal d'achat. Les barres vertes de l'histogramme confirment la tendance haussière.

5 Modèle de Machine Learning — Régression Linéaire

5.1 Configuration du modèle

Paramètre	Valeur
Algorithme	LinearRegression (Scikit-Learn)
Variable cible	Close_{t+1} — prix de clôture du lendemain
Features (13)	Open, High, Low, Close, Volume, MA_20, MA_50, RSI_14, Volatility_20, Price_Range, MACD, MACD_Signal, BB_Width
Prétraitement	StandardScaler ($\mu = 0, \sigma = 1$)
Split Train/Test	80% / 20% <i>chronologique</i> (pas aléatoire)
Entraînement	111 739 échantillons
Test	27 935 échantillons

Pourquoi un split chronologique ? Un split aléatoire introduit du *data leakage* : le modèle verrait des données futures lors de l’entraînement. Le split temporel simule correctement une utilisation réelle.

5.2 Résultats du modèle

MAE

RMSE

R²

0.1845 \$

0.4536 \$

0.9997

Le modèle explique **99,97%** de la variance des prix de clôture.

5.3 Graphiques du modèle




FIGURE 8 — Régression Linéaire — Prix réel (bleu) vs prix prédit (rouge) sur le jeu de test.




FIGURE 9 – Importance des features — coefficients absolus. Close, MA_20 et MA_50 dominent l'explication du prix du lendemain.




FIGURE 10 – Analyse des résidus — distribution (gauche) et résidus vs valeurs prédites (droite).

MAE = 0,1845 \$: En moyenne, le modèle se trompe de moins de **18 centimes** sur le prix du lendemain. Erreur relative $< 0,5\%$ pour un prix moyen de 39 \$.

$R^2 = 0,9997$: Ce score s'explique par la **forte autocorrélation des séries boursières** : le meilleur prédicteur du prix de demain est le prix d'aujourd'hui. Les résidus centrés sur 0 confirment l'absence de biais systématique. La distribution en cloche (gauche) indique que les erreurs sont symétriques. Le scatter (droite) montre une dispersion aléatoire sans pattern : bonne linéarité du modèle. Les queues légèrement épaisses reflètent les prix extrêmes (crises, booms) — normaux et attendus en finance.

Limites : La régression linéaire ne capture pas les comportements non-linéaires (paniques, bulles) ni les facteurs externes (taux, actualités). Des modèles comme **LSTM** ou **Random Forest** seraient plus adaptés pour des prédictions à moyen terme.

5.4 Prédiction Multi-Horizons

Pour répondre pleinement à la problématique de l'énoncé — *prévoir les prix futurs* — le modèle a été testé sur quatre horizons temporels distincts, en utilisant les mêmes 13 features et le même split chronologique 80/20.

Horizon	Période	MAE (\$)	RMSE (\$)	R ²
t+1	Lendemain	0.1845	0.4536	0.9997
t+5	1 semaine	0.4042	0.9607	0.9985
t+10	2 semaines	0.5702	1.3122	0.9972
t+21	1 mois	0.8660	1.8988	0.9941




FIGURE 11 – Dégradation du MAE, RMSE et R² avec l'horizon de prédiction. Le R² passe de 0,9997 (t+1) à 0,9941 (t+21).




FIGURE 12 – Réel vs Prédit pour les 4 horizons. L'écart entre les courbes bleue (réel) et rouge (prédit) s'agrandit progressivement avec l'horizon.

Analyse des résultats multi-horizons :

- **t+1** ($R^2=0,9997$, $MAE=0,18$ \$) : quasi-parfait — la forte autocorrélation journalière domine.
- **t+5** ($R^2=0,9985$, $MAE=0,40$ \$) : très bon — la tendance hebdomadaire reste bien capturée.
- **t+10** ($R^2=0,9972$, $MAE=0,57$ \$) : bon — utilisable opérationnellement pour une gestion à 2 semaines.
- **t+21** ($R^2=0,9941$, $MAE=0,87$ \$) : acceptable — la régression linéaire atteint ses limites à 1 mois.

Le MAE est multiplié par **4,7** entre t+1 et t+21, tandis que le R^2 ne baisse que de **0,0056** — ce qui confirme la robustesse du modèle sur des horizons courts à moyens.

Perspective : Pour des horizons supérieurs à 1 mois, des modèles capturant la non-linéarité sont recommandés : **LSTM** (dépendances temporelles longues), **Random Forest** ou **XGBoost** (interactions non-linéaires entre features).

5.5 Comparaison des Modèles de Régression

Modèle	MAE (\$)	RMSE (\$)	R^2
Régression Linéaire	0.1845	0.4536	0.9997
Random Forest	0.2124	0.4689	0.9996
Gradient Boosting	1.7726	1.9633	0.9937




FIGURE 13 – Comparaison MAE, RMSE et R^2 des 3 modèles de régression.

Interprétation :

- **Régression Linéaire** : $R^2=0.9997$ — excellente grâce à l'autocorrélation.
- **Random Forest** : capture les relations non-linéaires entre features.
- **Gradient Boosting** : apprend de ses erreurs itérativement.
- Le meilleur modèle est retenu pour les prédictions finales.

6 Bonus — Application Streamlit

Un tableau de bord interactif a été déployé sur Streamlit Community Cloud :

```
stock-dashboard-sg01-creqnabvnswpmyftuebkak.streamlit.app
```

Fonctionnalité	Description
Sélecteur de ticker	15 entreprises via menu déroulant
Sélecteur de période	1962 → 2024 + bouton <i>Toute la période</i>
5 métriques clés	Prix, variation, volume, volatilité, RSI
Onglet Prix & MA	Cours + MA20 + MA50 + Bandes de Bollinger
Onglet RSI	RSI(14) avec seuils surachat/survente
Onglet MACD	Signal + histogramme des divergences
Onglet Modèle ML	Prédictions vs réel + MAE/RMSE/R ²
Onglet Multi-Horizons	Prédictions t+1/t+5/t+10/t+21 + courbes de dégradation
Onglet Comparaison Modèles	Comparaison MAE/RMSE/R ² des 3 modèles

7 Conclusion

Ce projet a permis de construire un **pipeline complet de Data Science financière**, de l’exploration des données brutes jusqu’au déploiement d’une application interactive.

Réponse à la Problématique

- Le secteur d’activité** : les actions technologiques (TSLA, NVDA) sont 3 à 5 fois plus volatiles que les valeurs défensives (KO, WMT) ;
- Les indicateurs techniques** (RSI, MACD, BB_Width) capturent les phases de surachat/survente précédant les retournements de marché ;
- Le volume de transactions** : les journées exceptionnelles signalent des événements majeurs (crises, annonces) ;
- Les corrélations sectorielles** : les chocs systémiques (2008, COVID 2020) affectent simultanément tous les actifs corrélés.

Le modèle de régression linéaire atteint un **R² de 0,9997** à t+1 et reste robuste jusqu’à 1 mois (R²=0,9941 à t+21), démontrant la forte autocorrélation des séries boursières à court et moyen terme.

*Mini-Projet SG01 — Ons Gaaya — GL4 A1 — Python EDA & Machine Learning
— 2025/2026*

Encadrante : Dr. Boutheina BEN ISMAIL — EPI Sousse, DIGITAL SCHOOL